



Предиктивное обслуживание в
промышленности, энергетике и
электрохимии



ИИ для науки об аккумуляторах

Цель: более умные и долговечные аккумуляторы на основе моделей, управляемых данными

Задачи:


- DL-модели на реальных данных (совм. с HKUST)
- Суррогатные ИИ-инструменты (физика + данные)
- Пайплайны обнаружения аномалий
- Кросс-доменное обучение для новых химий
- Публикации и выступления на конференциях



Ссылки:

[BatteryLife: A Comprehensive Dataset and Benchmark](#)

[Battery safety: Machine learning-based prognostics](#)





ИИ для науки об аккумуляторах

➔ Прогнозирование ёмкости аккумулятора

Модель долгосрочного прогноза деградации и ресурса аккумулятора — работает на ограниченных данных, масштабируется и адаптируется к новым химиям.

Ключевая идея: физически информированная аугментация данных + NeuralDE



Партнёр: эксперименты с передовыми аккумуляторами



Metrics	Models	Start cycle			
		150	250	500	750
MAE ↓	TimesNet [51]	137.62 ± 22.79	114.86 ± 21.76	73.67 ± 17.98	17.55 ± 5.98
	SCINet [52]	154.00 ± 62.37	109.65 ± 47.71	74.40 ± 27.32	22.49 ± 15.17
	PatchTST [53]	128.29 ± 43.79	119.35 ± 28.71	77.88 ± 20.11	26.65 ± 1.79
	MLP	161.87 ± 6.03	154.94 ± 4.78	90.39 ± 3.86	16.97 ± 0.73
	LSTM [50]	221.19 ± 3.99	189.55 ± 2.92	127.58 ± 2.14	31.70 ± 1.72
	Chronos [47]	302.18	134.16	75.05	24.57
	AttMoE [48]	103.14 ± 33.11	109.56 ± 47.23	58.36 ± 27.32	24.74 ± 7.78
	STL-BCDP [49]	142.10 ± 108.23	79.04 ± 25.07	85.59 ± 53.61	71.23 ± 75.73
	Our model	64.78 ± 7.18	60.06 ± 10.34	47.97 ± 3.64	15.85 ± 0.97
RMSE ↓	TimesNet [51]	159.16 ± 26.50	134.42 ± 24.47	84.21 ± 19.09	20.22 ± 6.39
	SCINet [52]	208.98 ± 112.41	130.51 ± 43.16	82.57 ± 28.30	25.10 ± 17.12
	PatchTST [53]	158.29 ± 53.86	149.01 ± 34.11	91.57 ± 23.83	29.61 ± 2.01
	MLP	199.86 ± 7.42	190.96 ± 5.07	108.08 ± 4.37	19.78 ± 0.84
	LSTM [50]	262.07 ± 4.06	226.13 ± 2.81	147.26 ± 2.18	36.57 ± 1.85
	Chronos [47]	375.97	173.50	93.32	28.84
	AttMoE [48]	129.26 ± 39.09	137.69 ± 57.17	68.88 ± 27.21	27.85 ± 7.98
	STL-BCDP [49]	171.56 ± 119.83	98.79 ± 30.45	105.52 ± 70.75	76.79 ± 79.81
	Our model	96.75 ± 27.13	58.43 ± 21.92	41.63 ± 18.83	17.40 ± 1.2
R^2 ↑	TimesNet [51]	-0.50 ± 0.37	-0.43 ± 0.29	-0.47 ± 0.17	-0.07 ± 0.31
	SCINet [52]	-2.76 ± 2.68	-1.33 ± 0.39	-1.31 ± 3.68	-1.43 ± 5.87
	PatchTST [53]	-0.14 ± 0.88	-0.42 ± 0.52	-0.67 ± 0.72	-1.39 ± 0.35
	MLP	-0.67 ± 0.14	-1.26 ± 0.10	-0.98 ± 0.15	-0.07 ± 0.13
	LSTM [50]	-2.18 ± 0.12	-2.12 ± 0.09	-2.54 ± 0.11	-1.66 ± 0.27
	Chronos [47]	-39.71	-0.78	-3.22	-1.37
	AttMoE [48]	-1.46 ± 1.79	-3.75 ± 4.42	-0.17 ± 0.24	-1.67 ± 2.39
	STL-BCDP [49]	-1.61 ± 3.47	0.16 ± 0.39	-1.93 ± 2.94	-7.34 ± 8.53
	Our model	0.01 ± 0.32	0.64 ± 0.02	0.49 ± 0.08	0.27 ± 0.02




ИИ для науки об аккумуляторах

➔ Оценка ресурса аккумулятора электромобиля


Модель точной оценки аккумуляторов электромобилей (один из самых быстрорастущих рынков в мире).

Проблема: проприетарные и специфичные для каждого производителя системы управления батареями.

Ключевая идея: физически обоснованный FNO + DualHead



Быстрое дообучение для нового производителя



Примерные задачи проекта

1. Бенчмарк нейрооператоров на нестационарных (transient) профилях разряда

честное сравнение LSTM/GRU, Transformer (PatchTST), **FNO** (наш baseline) и простого 1D-варианта на dynamic-load профилях (drive cycles UDDS/HWFET/US06 + синтетические токовые сегменты поверх реальных ячеек)

Бенчмарк устойчивости к шуму, пропускам и нерегулярной дискретизации

2. Data-centric scaling law: независимые ячейки против сегментов

что выгоднее - дольше мерить имеющуюся ячейку, сильнее сегментировать или поставить новый ageing-эксперимент? Пример: 100 ячеек × 10 сегментов и 10 × 100 дают одинаковое N_{samples} , но разную обобщающую способность

3. Калиброванная неопределённость поверх FNO-оценки ёмкости

Обернуть готовый FNO/NeuralODE в ensembles, MC-dropout, conformal / split-conformal и Bayesian last-layer; сравнить по калибровке (coverage, CRPS, reliability diagram), а не только по RMSE

4. Physics-informed neural operators для переноса между различными химическими системами батарей

ИИ для электрохимических процессов

Цель: Комплекс ML-моделей для анализа и прогнозирования мембранного электролиза воды

Решаемые задачи:

- Прогнозирование временных зависимостей электрохимических параметров по начальным условиям
- Экстраполяция характеристик ячейки за пределы исследованных рабочих диапазонов
- Обнаружение скрытых зависимостей и паттернов в данных
- Предсказание кинетики и стадии процессов
- Анализ режимов работы: пакетный / непрерывный / интегрированный

Производство «зеленого» водорода с ИИ

